Umetna inteligenca kot vir raziskav in razvoja ter dolgoročne gospodarske rasti: ZDA v obdobju 2010–2025

Andraž Ajdovec Tin Cvek Jan Hrovat Miha Ručigaj

oktober, 2026

Predmet: Makroekonomija
Seminarska naloga
Univerza: *Fakulteta za matematiko in fiziko*
Mentor: *Jan Grobovšek*

Kazalo

1 Uvod **3**
1.1 Širši okvir in pomen problematike . . . 3
1.2 Predstavitev izbranega primera: ZDA v obdobju 2010–2025 . . . 3
1.3 Raziskovalno vprašanje in hipoteze . . . 4
1.4 Struktura naloge . . . 4

2 Podatkovna analiza **5**
2.1 Viri podatkov in izbor spremenljivk . . . 5
2.2 Metoda analize . . . 6
2.3 Razvoj izdatkov za raziskave in razvoj . . . 6
2.4 Federalna vlaganja v UI R&R . . . 7
2.5 Ustvarjanje novega znanja: UI-patenti . . . 8
2.6 Razvoj skupne faktorske produktivnosti . . . 8
2.7 Primerjava UI-kazalnikov, inovacij in TFP . . . 9

3 Teoretični okvir gospodarske rasti **10**
3.1 Viri dolgoročne rasti . . . 10
3.2 Solow–Swanov model . . . 10
3.3 Računovodstvo rasti in TFP . . . 11
3.4 Endogena rast in vloga R&R . . . 12
3.5 Umetna inteligenca v modelih rasti: hipoteze . . . 13

4 Uporaba modela in povezava s podatki **14**
4.1 R&R in ustvarjanje novega znanja . . . 14
4.2 Umetna inteligenca in produktivnost raziskovalnega procesa . . . 14
4.3 Prenos novega znanja v TFP . . . 14
4.4 Primerjava napovedi modela z ugotovitvami . . . 15
4.5 Primerjava napovedi modela z ugotovitvami . . . 15

5 Kritična presoja in zaključek **17**
5.1 Odgovor na raziskovalno vprašanje . . . 17
5.2 Presoja in omejitev analize . . . 17
5.3 Zaključek . . . 18

Literatura in viri **20**

1 Uvod

1.1 Širši okvir in pomen problematike

Teorija rasti je osrednja makroekonomska tema (Polanec 2014, str. 1), saj je rast za blaginjo dolgoročno pomembnejša od nihanj poslovnega cikla (Garín, Lester in Sims 2021, str. 5). Že majhne razlike v povprečni stopnji rasti se skozi čas močno seštejejo: ena odstotna točka višja rast v štiridesetih letih pomeni približno 49 % višjo raven dohodka na prebivalca ($1{,}01^{40} \approx 1{,}49$) (Polanec 2014, str. 4).

Solow–Swanov model pokaže, da povečanje stopnje varčevanja ne ustvari trajne rasti in da na dolgi rok rast outputa na delavca določa le rast tehnologije oziroma produktivnosti (Polanec 2014, str. 13–14; Garín, Lester in Sims 2021, str. 108). Ker model to rast privzame kot eksogeno, je ne pojasni (Polanec 2014, str. 18; Garín, Lester in Sims 2021, str. 129). Produktivnost je pomembna tudi za razlike v dohodku med državami, katerih razlog so razlike v skupni faktorski produktivnosti (TFP) (Garín, Lester in Sims 2021, str. 143–144). TFP pri tem ni neposredno opazljiva, temveč jo merimo kot ostanek, ki ga ne pojasnijo merljivi inputi dela in kapitala (Solowov rezidual) (Polanec 2014, str. 22; Garín, Lester in Sims 2021, str. 142).

Vir produktivnosti je zato treba iskati zunaj Solow–Swanovega modela. To počne teorija endogene rasti, po kateri je tehnološki napredek rezultat namernih vlaganj v znanje in raziskave, ki se povrnejo iz prihodnjih dobičkov (Polanec 2014, str. 18). Raziskave in razvoj (R&R) so lahko pomemben vir rasti TFP: navedene ocene govorijo o do 66 % rasti TFP (Polanec 2014, str. 28). Umetna inteligenca (UI) v nalogi nastopa kot možen dejavnik, ki poveča učinkovitost raziskovalnega procesa in bi tako po mehanizmu endogene rasti lahko zvišala nastajanje znanja in TFP. To je izhodiščna predpostavka, ki jo preizkušamo, ne uveljavljena ugotovitev. Učinek tudi ni nujno takojšen: splošnonamenske tehnologije zahtevajo komplementarne investicije in učenje, zato je rast sprva lahko počasnejša (Polanec 2014, str. 28).

1.2 Predstavitev izbranega primera: ZDA v obdobju 2010–2025

Za empirični del smo izbrali ZDA. Po podatkih NCSES so skupni izdatki za R&R leta 2023 znašali približno 937 milijard USD, ocena za 2024 pa je 993 milijard USD (National Center for Science and Engineering Statistics 2026). Več kot 95 % svetovnih R&R izvaja v razvitih državah (Polanec 2014, str. 31–32), kamor spadajo tudi ZDA, zato je njihova dolgoročna rast v obravnavanih modelih pretežno odvisna od rasti produktivnosti in ne od dohitevanja: država v ustaljenem stanju raste le toliko, kot raste produktivnost (Garín, Lester in Sims 2021, str. 130, 135), med razvitimi državami pa bolj razvite rastejo počasneje kot manj razvite (Polanec 2014, str. 5–6). Gre za našo interpretacijo teh virov.

Obdobje 2010–2025 razdelimo na tri podobdobja (2010–2014, 2015–2019 in 2020–

2025). To je razdelitev za potrebe primerjave in ne zgodovinska periodizacija razvoja UI. Pri razlagi je treba upoštevati, da se je generativna UI množično razširila šele po izidu orodja ChatGPT 30. novembra 2022 (OpenAI 2022), da začetek zadnjega podobdobja (2020–2022) zaznamuje pandemija ter da se serije R&R in UI-patentov končajo prej kot serija TFP (v naši analizi leta 2023). Podatki o R&R in patentih zato zajemajo generativno UI le za eno leto.

V analizi spremljamo gibanje izdatkov za R&R, federalna vlaganja v UI, ustvarjanje novega znanja prek UI-patentov ter razvoj TFP.

1.3 Raziskovalno vprašanje in hipoteze

Glavno raziskovalno vprašanje: Katera od hipotez o vlogi umetne inteligence v procesu gospodarske rasti je najbolj skladna z gibanjem izdatkov za R&R, UI-patentov in TFP v ZDA v obdobju 2010–2025?

Na to vprašanje odgovorimo prek treh podvprašanj:

1. Ali so se raziskovalni inputi, merjeni s skupnimi izdatki za R&R in federalnimi vlaganji v UI, povečali?

2. Ali je naraščala inovacijska aktivnost, merjena z UI-patenti?

3. Ali se je rast TFP pospešila in ali je velikost sprememb v skladu s tem, kar bi lahko pričakovali od UI?

Za odgovor v poglavju 3 opredelimo štiri hipoteze: H1 (UI ne spremeni dolgoročne rasti) (Polanec 2014, str. 13), H2 (UI poveča stopnjo tehnološkega napredka) (Polanec 2014, str. 14–15; Garín, Lester in Sims 2021, str. 108–109), H3 (UI poveča raziskovalne inpute ali njihovo produktivnost) (Polanec 2014, str. 27–28) in H4 (UI poveča donose znanja tako, da se rast pospešuje) (Polanec 2014, str. 26–27). Ne poskušamo dokazati vzročnosti, temveč preverjamo, katera hipoteza je z opaženimi trendi najbolj skladna in kaj bi jo ovrglo. Pri tem so pomembne tri omejitve: TFP je ostanek, v katerem končajo tudi napake merjenja inputov (Polanec 2014, str. 23–24), neposrednih podatkov o zasebnih vlaganjih v UI nimamo, UI-patenti in federalna vlaganja pa pokrivajo le del dejavnosti.

1.4 Struktura naloge

V poglavju 2 predstavimo uporabljene podatke in analiziramo razvoj izdatkov za R&R, federalnih vlaganj v UI, UI-patentne aktivnosti ter TFP v ZDA. V poglavju 3 predstavimo teoretični okvir gospodarske rasti, pri čemer se osredotočimo na Solow–Swanov model, računovodstvo gospodarske rasti, teorijo endogene rasti in hipoteze o vlogi UI. V poglavju 4 napovedi hipotez primerjamo z opaženimi podatki, v poglavju 5 pa podamo

kritično presojo ugotovitev, izpostavimo omejitve analize in odgovorimo na raziskovalno vprašanje.

2 Podatkovna analiza

V tem poglavju s podatki za ZDA v obdobju 2010–2025 analiziramo povezavo med raziskavami in razvojem (R&R), umetno inteligenco (UI), ustvarjanjem novega tehnološkega znanja in skupno faktorsko produktivnostjo (TFP). Namen analize je preveriti, ali se je v obdobju hitrega razvoja UI povečal obseg raziskovalnih vložkov, ali je temu sledila večja merljiva inovacijska aktivnost in ali je mogoče podoben vzorec opaziti tudi pri agregatni produktivnosti.

2.1 Viri podatkov in izbor spremenljivk

Za analizo uporabimo štiri skupine kazalnikov. Širši obseg raziskovalne dejavnosti merimo s skupnimi izdatki ZDA za R&R, ki jih objavlja National Center for Science and Engineering Statistics (NCSES). Usmerjenost raziskovalnih sredstev v UI spremljamo s podatki programa Networking and Information Technology Research and Development (NITRD) o federalnih ne-obrambnih izdatkih za UI R&R. Kot približek ustvarjanju novega tehnološkega znanja uporabimo patentne dokumente, povezane z UI, iz podatkovnega niza USPTO Artificial Intelligence Patent Dataset. Končni makroekonomski kazalnik je rast TFP v zasebnem nekmetijskem poslovnem sektorju, ki jo objavlja U.S. Bureau of Labor Statistics (BLS).

Kazalniki predstavljajo različne stopnje istega procesa: izdatki za R&R merijo raziskovalne vložke, patentna aktivnost je približek nastajanju formaliziranega tehnološkega znanja, TFP pa meri spremembe učinkovitosti uporabe dela in kapitala na ravni gospodarstva.

Tabela 1: Kazalniki, uporabljeni v empirični analizi

Koncept	**Kazalnik**	**Obdobje**	**Vir**
Splošna vlaganja v R&R	Izdatki ZDA za R&R	2010–2023	NCSES/NSF
UI-specifični R&R	Federalni ne-obrambni izdatki za UI R&R	2019–2025	NITRD
Novo tehnološko znanje	UI-patenti oziroma patentni dokumenti	2010–2023	USPTO
Produktivnost	Rast TFP v zasebnem nekmetijskem poslovnem sektorju	2010–2025	BLS

2.2 Metoda analize

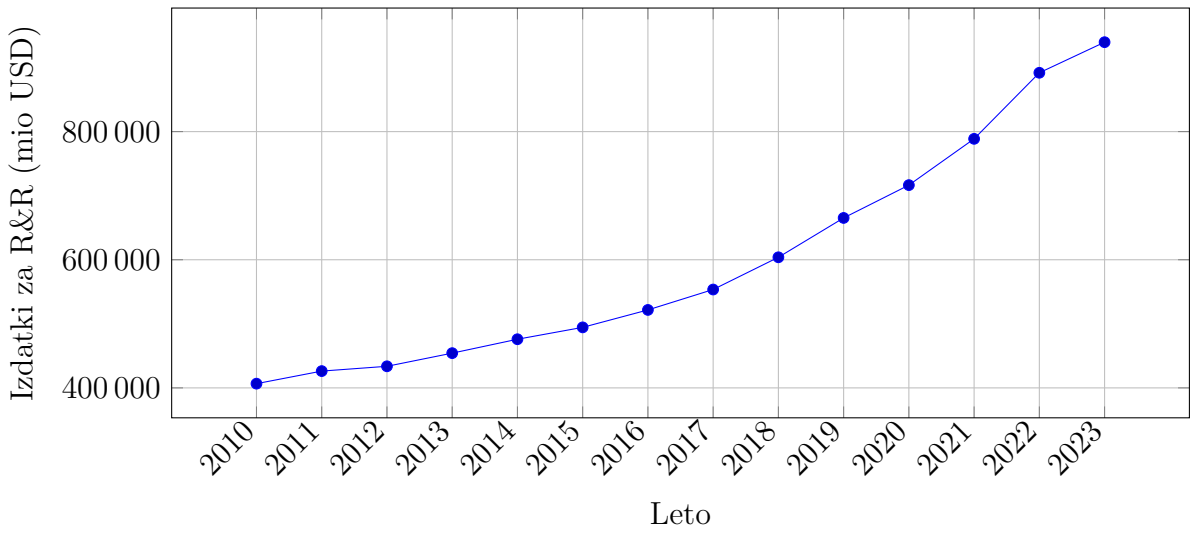
Empirični del temelji na opisni analizi časovnih vrst. Pri posameznem kazalniku najprej prikažemo njegovo gibanje skozi čas, nato pa primerjamo obdobja 2010–2014, 2015–2019 in 2020–2025. Ker vse serije ne pokrivajo celotnega obdobja, uporabimo pri posameznem kazalniku samo leta, za katera so na voljo primerljivi uradni podatki. Manjkajočih vrednosti ne interpoliramo.

Pri denarnih spremenljivkah razlikujemo med nominalnimi in realnimi vrednostmi. Skupni ameriški izdatki za R&R so v osnovnem prikazu izraženi v tekočih dolarjih, zato njihove rasti ni mogoče v celoti pripisati povečanju realnega obsega raziskovalne dejavnosti. Pri interpretaciji zato upoštevamo tudi realne stopnje rasti in delež izdatkov za R&R v BDP.

Analiza poteka v treh korakih. Najprej obravnavamo skupne in UI-specifične raziskovalne vložke, nato patentno aktivnost kot približek ustvarjanju novega znanja in nazadnje gibanje TFP. Učinki nove tehnologije na agregatno produktivnost se lahko pojavijo z zamikom, saj njena uvedba zahteva dodatne investicije, organizacijske spremembe in učenje. Opisna analiza zato omogoča preverjanje časovnega zaporedja in skladnosti podatkov s teoretičnim mehanizmom, ne omogoča pa dokazovanja vzročnosti. Rezultate razumemo kot opisno preverjanje povezav in ne kot oceno čistega vzročnega učinka UI na TFP.

2.3 Razvoj izdatkov za raziskave in razvoj

NCSES poroča o skupnih ameriških izdatkih za R&R po sektorjih. Za analizo uporabimo uradno časovno serijo za obdobje 2010–2023 (National Center for Science and Engineering Statistics 2026).



Slika 1: Skupni izdatki za R&R v ZDA, 2010–2023

Vir: NCSES/NSF; lastna priprava.

Podatki kažejo izrazito povečanje nominalnih ameriških izdatkov za R&R. Skupni izdatki vseh izvajalskih sektorjev so se povečali s približno 406,6 milijarde USD leta 2010 na približno 937 milijarde USD leta 2023 (National Center for Science and Engineering Statistics 2026). To pomeni več kot podvojitev nominalne vrednosti v trinajstih letih. Ker gre za tekoče dolarje, del rasti odraža rast cen, zato nominalnega povečanja ne smemo enačiti z realnim povečanjem količine raziskovalne dejavnosti.

Tudi realni podatki kažejo, da rast ni posledica zgolj inflacije. NCSES za obdobje 2013–2023 poroča približno 4,8-odstotno povprečno letno realno rast skupnih izdatkov za R&R, merjeno v konstantnih dolarjih. Hkrati se je povečala intenzivnost R&R: delež izdatkov za R&R je bil od leta 2019 nad 3 %, leta 2023 pa je znašal približno 3,39 % (National Center for Science and Engineering Statistics 2026). Raziskovalna dejavnost je torej rasla hitreje kot gospodarstvo kot celota.

Glavnino ameriškega R&R je izvajal in financiral poslovni sektor. To je skladno z endogeno teorijo rasti, v kateri podjetja vlagajo v ustvarjanje novega znanja zaradi pričakovanih prihodnjih donosov. Sam trend skupnih izdatkov še ne pove, kolikšen del dodatnega raziskovanja je neposredno povezan z UI, kaže pa na širitev raziskovalne osnove za inoviranje.

2.4 Federalna vlaganja v UI R&R

Bolj neposreden kazalnik raziskovalne dejavnosti na področju UI so federalna ne-obrambna vlaganja v UI R&R, ki jih objavlja NITRD (Networking and Information Technology Research and Development Program 2024). Pri teh podatkih je treba razlikovati med dejansko porabo, odobrenimi sredstvi in proračunskimi zahtevami.

NITRD razlikuje med postavko *Core UI* in širšim seštevkom UI R&R. *Core UI* zajema raziskave, pri katerih je UI neposredni predmet, na primer strojno učenje, računalniški vid, jezikovni algoritmi in arhitekture nevronskih mrež. Širši seštevek vključuje tudi dejavnosti, evidentirane na drugih programskih področjih, vendar z pomembno komponento UI (Networking and Information Technology Research and Development Program 2024).

Tabela 2: Federalni UI R&R – izbrana leta

Fiskalno leto	**Core UI (mio USD)**	**Skupaj (mio USD)**
FY2023 dejansko	1.914,2	3.121,9
FY2024 odobreno	1.789,0	2.977,5
FY2025 zahteva	1.954,5	3.316,1

Vir: NITRD; lastna priprava.

V FY2023 je ne-obrambna federalna poraba za UI R&R znašala približno 3,12 milijarde USD, od tega 1,91 milijarde USD za *Core UI*. Za FY2024 je bilo odobrenih približno 2,98

milijarde USD, proračunska zahteva za FY2025 pa je znašala približno 3,32 milijarde USD. Če bi bila zahteva za FY2025 v celoti realizirana, bi to pomenilo približno 11,4-odstotno povečanje glede na odobreno raven FY2024. Podatka za FY2025 zato ne interpretiramo kot že realizirano porabo.

Podatki od FY2019 naprej kažejo, da je UI postala pomembno področje federalnega financiranja raziskav. V kombinaciji z rastjo skupnih ameriških izdatkov za R&R to kaže na povečanje raziskovalnih vložkov, povezanih tako s širšo raziskovalno dejavnostjo kot posebej z razvojem UI.

2.5 Ustvarjanje novega znanja: UI-patenti

USPTO Artificial Intelligence Patent Dataset omogoča identifikacijo patentnih dokumentov, povezanih z UI, do leta 2023 (United States Patent and Trademark Office 2025). Posodobljeni podatkovni niz zajema 15,4 milijona patentnih dokumentov, objavljenih do leta 2023, in jih razvršča glede na verjetnost, da vsebujejo tehnologijo UI.

Patentni dokumenti niso popolna mera inovacij. Vsa nova znanja niso patentirana, podjetja lahko inovacije varujejo s poslovnimi skrivnostmi, posamezni patenti pa se močno razlikujejo po tehnološkem in gospodarskem pomenu. Število patentnih dokumentov zato razumemo kot približek intenzivnosti formalizirane izumiteljske dejavnosti.

Posodobitev podatkovnega niza kaže dolgoročno rast števila patentnih dokumentov, ki jih model prepozna kot povezane z UI. Leta 2023 je bilo pri 50-odstotnem klasifikacijskem pragu prepoznanih nekaj več kot 210.000 takšnih dokumentov (United States Patent and Trademark Office 2025). Razvoj je skladen z rastjo raziskovalnih aktivnosti, vendar iz razpoložljivih podatkov ni mogoče oblikovati enotne agregirane letne serije. Zato letnega grafa patentov ne prikazujemo, da ne bi ustvarili navidezne natančnosti.

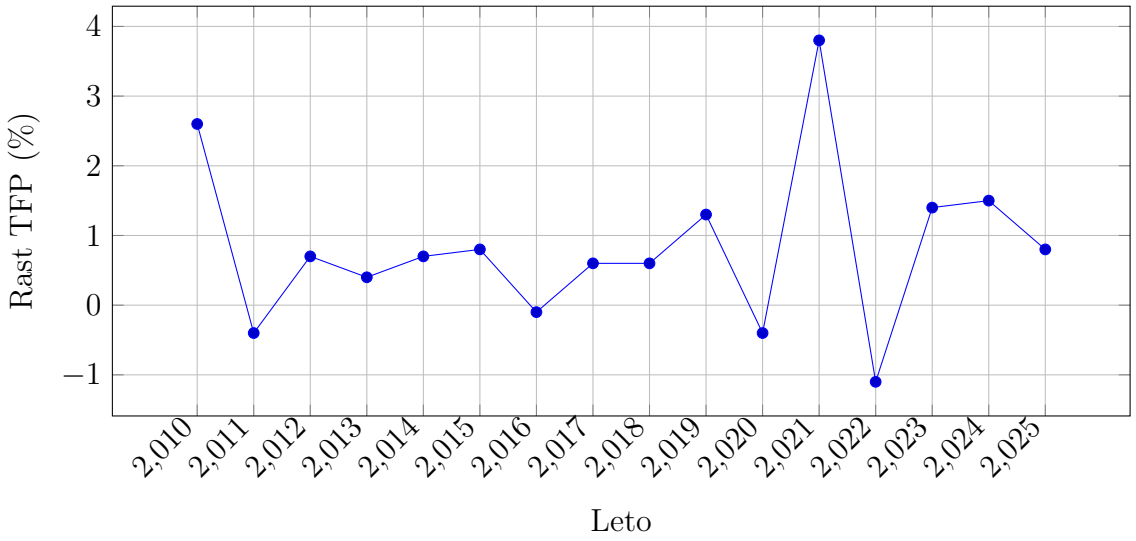
2.6 Razvoj skupne faktorske produktivnosti

BLS definira TFP kot razmerje med indeksom realnega outputa in indeksom kombiniranih vložkov dela in kapitala. Za leto 2025 BLS poroča o 0,8-odstotni rasti TFP v zasebnem nekmetijskem poslovnem sektorju (U.S. Bureau of Labor Statistics 2026).

Gibanje TFP je precej bolj volatilno kot gibanje izdatkov za R&R. V obdobju 2010–2019 so se letne stopnje rasti večinoma gibale blizu ničle oziroma okoli enega odstotka. Pandemsko obdobje je povzročilo velika nihanja: po padcu leta 2020 je leta 2021 sledil močan skok, nato padec leta 2022, v letih 2023 in 2024 pa ponovno povečanje. Leta 2025 je BLS poročal o 0,8-odstotni rasti.

Povprečna letna rast TFP je znašala približno 0,80 % v letih 2010–2014, 0,64 % v letih 2015–2019 in 1,00 % v obdobju 2020–2025. Zadnje povprečje je treba interpretirati previdno, ker ga močno določajo pandemska nihanja. BLS za poslovni cikel 2019–2025 ocenjuje približno 1,0-odstotno povprečno letno rast TFP, za cikel 2007–2019 pa približno

0,6 %. To je skladno z možnostjo določenega pospeška produktivnosti, vendar samo časovno sovpadanje ne dokazuje, da je bil vzrok UI. V istem obdobju so se spreminjali struktura dela, kapitalske investicije, dobavne verige, fiskalna politika in drugi dejavniki.



Slika 2: Letna rast TFP v zasebnem nekmetijskem poslovnem sektorju ZDA, 2010–2025

Vir: BLS; lastna priprava.

2.7 Primerjava UI-kazalnikov, inovacij in TFP

Primerjava kaže najjasnejšo rast raziskovalnih vložkov in UI-povezane patentne aktivnosti. Skupni ameriški izdatki za R&R so se v analiziranem obdobju močno povečali, po letu 2019 pa so večmilijardne ravni dosegla tudi federalna vlaganja v UI R&R. Pri TFP je slika manj enotna: rast je bila pozitivna, vendar volatilna in občutljiva na pandemske ter druge makroekonomske šoke.

Tabela 3: Primerjava glavnih kazalnikov po podobdobjih

Kazalnik	**2010–2014**	**2015–2019**	**2020–2025**
Nominalni CAGR R&R	4,0 %	7,7 %	9,5 % (2020–2023)
Federalni UI R&R	brez primerljive serije	začetek serije FY2019	rast do večmilijardne ra
UI-patentni dokumenti	rast	nadaljnja rast	visoka raven do 202
Povprečna rast TFP	0,80 %	0,64 %	1,00 %

Podatki kažejo povečanje raziskovalnih vložkov in inovacijske aktivnosti, medtem ko je razvoj agregatne TFP manj enakomeren. Iz časovnega sovpadanja ne moremo sklepati, da je rast UI povzročila rast produktivnosti. Teoretični okvir v naslednjem poglavju pojasni, kako se raziskovalni vložki in nastajanje novega znanja lahko povežejo z dolgoročno

gospodarsko rastjo, razdelek 3.5 pa opredeli hipoteze o vlogi UI in njihove napovedi za te kazalnike.

3 Teoretični okvir gospodarske rasti

Poglavje predstavi, kaj teorija pove o virih dolgoročne rasti, kako se TFP meri in kako lahko UI vstopi v modele rasti. Iz tega izpeljemo štiri hipoteze H1–H4, ki jih v poglavju 4 primerjamo s podatki.

3.1 Viri dolgoročne rasti

Dolgoročno rast lahko razlagamo z akumulacijo proizvodnih dejavnikov, predvsem fizičnega in človeškega kapitala, ali z rastjo skupne faktorske produktivnosti (TFP). Ta po zapiskih odraža novo tehnologijo, pa tudi institucije, delež države v BDP in odprtost mednarodni trgovini (Polanec 2014, str. 8). Učbenik med dejavniki produktivnosti našteva izobrazbo, institucije, finančni sistem, trgovino in infrastrukturo (Garín, Lester in Sims 2021, str. 144–145). Gibanja TFP zato ni mogoče samodejno pripisati eni sami tehnologiji; to omejitev upoštevamo pri preizkusu hipotez. Človeški kapital je znanje, utelešeno v delavcih, tehnologija pa je v zapiskih opisana kot načrt (angl. *blueprint*), torej zapis, kako se proizvod proizvaja (Polanec 2014, str. 21).

3.2 Solow–Swanov model

Model ima dva proizvodna faktorja, kapital K in delo L, ter eno homogeno dobrino, ki se lahko potroši ali investira. Gospodarstvo je zaprto, zato so investicije enake varčevanju (Polanec 2014, str. 9). Produkcijska funkcija je

$$Y(t) = F\left[K(t), A(t)L(t)\right], \tag{1}$$

kjer je A delo povečujoča tehnologija, AL pa efektivno delo (Polanec 2014, str. 10); učbenik jo označuje z Z_t (Garín, Lester in Sims 2021, str. 108–109). Funkcija ima konstantne donose obsega in padajoče mejne donose posameznega faktorja (Polanec 2014, str. 10–11; Garín, Lester in Sims 2021, str. 109). Kapital se kopiči iz varčevanja s stopnjo s in se amortizira s stopnjo δ, delo raste po stopnji n, tehnologija po stopnji x (Polanec 2014, str. 10):

$$\dot{K}(t) = sY(t) - \delta K(t), \qquad \frac{\dot{L}(t)}{L(t)} = n, \qquad \frac{\dot{A}(t)}{A(t)} = x. \tag{2}$$

Zaradi konstantnih donosov lahko output na enoto efektivnega dela zapišemo kot $y = f(k)$, kjer je $k = K/(AL)$ kapital na enoto efektivnega dela, $f(k) = F(k, 1)$ pa izpolnjuje $f(0) = 0$, $f'(k) > 0$, $f''(k) < 0$ in Inadine pogoje (Polanec 2014, str. 11–12). Dinamika

kapitala je

$$\dot{k}(t) = sf\Big(k(t)\Big) - (n + x + \delta)\, k(t), \tag{3}$$

v ustaljenem stanju pa so dejanske investicije enake nadomestitvenim, $sf(k^*) = (n + x + \delta)k^*$ (Polanec 2014, str. 12–13).

V ustaljenem stanju output na delavca raste po stopnji x, agregatni output pa po stopnji $x + n$ (Polanec 2014, str. 13; Garín, Lester in Sims 2021, str. 130). Višja stopnja varčevanja dvigne raven kapitala in outputa, ne pa trajne stopnje rasti (Polanec 2014, str. 13–14; Garín, Lester in Sims 2021, str. 108). Ker je x v modelu dan od zunaj, model ne pojasni izvora rasti (Polanec 2014, str. 18; Garín, Lester in Sims 2021, str. 129).

Za nalogo je pomembno, kaj model napove, če UI poveča x (hipoteza H2). Za Cobb–Douglasovo funkcijo $f(k) = k^\alpha$, kjer je α delež kapitala v dohodku (po zapiskih okoli 1/3, po učbeniku za ZDA okoli 0,35) (Polanec 2014, str. 9, 23; Garín, Lester in Sims 2021, str. 63), je rast agregatnega outputa

$$g_Y = \alpha \left(\frac{sf(k)}{k} - \delta \right) + (1 - \alpha)(n + x) \tag{4}$$

(Polanec 2014, str. 14). Če gospodarstvo izhaja iz ustaljenega stanja in se x poveča za Δx, se kapital na enoto efektivnega dela začne zmanjševati, zato rast outputa na enoto efektivnega dela rahlo upade (Polanec 2014, str. 14–15). Rast agregatnega outputa pa v trenutku spremembe poskoči za $(1 - \alpha)\Delta x$ in nato postopoma doseže novo dolgoročno raven, ki je za Δx višja od prejšnje (lastna izpeljava iz enačbe (4)).

3.3 Računovodstvo rasti in TFP

Računovodstvo rasti razdeli rast BDP na prispevke merljivih inputov in preostanek, ki ga pripišemo TFP. Ker tehnologije ne moremo meriti neposredno, TFP ocenimo rezidualno (Polanec 2014, str. 22). Naj bo T raven TFP in $Y = T\, K^\alpha L^{1-\alpha}$ (Garín, Lester in Sims 2021, str. 142). Potem velja

$$g_Y = g_T + \alpha g_K + (1 - \alpha) g_L, \qquad g_T = g_Y - \alpha g_K - (1 - \alpha) g_L \tag{5}$$

(Polanec 2014, str. 23). Zapiski rast TFP označujejo z isto črko x kot rast tehnologije, vendar se obe ujemata le pri tej obliki funkcije. Pri delo povečujoči tehnologiji iz enačbe (1) je $K^\alpha (AL)^{1-\alpha} = A^{1-\alpha} K^\alpha L^{1-\alpha}$, zato je $g_T = (1 - \alpha)x$ (lastna izpeljava).

Ker je TFP ostanek, vsebuje tudi napake merjenja kakovosti dela in kapitala, zato lahko njen delež v rasti precenimo (Polanec 2014, str. 23–24). Zapiski opozarjajo še, da višja TFP poveča mejni produkt kapitala in s tem spodbudi investicije, zato rast kapitala ni nujno vzrok rasti (Polanec 2014, str. 24). V empiričnem delu uporabimo uradno serijo BLS za zasebni ne-kmetijski poslovni sektor, ki TFP izračuna kot razmerje med indeksom

realnega outputa in indeksom kombiniranih inputov (U.S. Bureau of Labor Statistics 2026).

3.4 Endogena rast in vloga R&R

Ker Solow–Swanov model rast tehnologije privzame, jo endogena teorija poskuša pojasniti. Ustvarjanje tehnologije je podobno kot kapital povezano s stroški, ki jih podjetja krijejo iz prihodnjih dobičkov (Polanec 2014, str. 18). Najpreprostejši endogeni model je AK model, $Y = AK$, v katerem kapital (v širšem smislu, vključno s človeškim) nima padajočih donosov, A pa je tehnološka konstanta (Polanec 2014, str. 19). Rast dohodka na osebo je tedaj

$$g_y = sA - (n + \delta) \tag{6}$$

in je določena s parametri modela, ne z začetno ravnjo dohodka (Polanec 2014, str. 19–20).

Za R&R je pomembnejša različica z eksternalijami znanja (Polanec 2014, str. 25–27; Romer 1986). Naj bo h znanje podjetja, $\bar{h}$ povprečno znanje v gospodarstvu in l delo. Podjetje i proizvaja

$$y_i = \bar{h}^{\beta}\, h_i^{\varphi}\, l_i^{1-\varphi}, \tag{7}$$

pri čemer smo eksponent lastnega znanja označili s φ namesto z α kot v zapiskih, da ga ne zamenjamo z deležem kapitala. Podjetja ostajajo konkurenčna, eksternalija pa nastane prek $\bar{h}$ (Polanec 2014, str. 26). Znanje se kopiči iz investicij, $h_{t+1} = h_t + s\, y_t$ (brez amortizacije), zato je pri enakih podjetjih ($h_i = \bar{h} = h$) stopnja rasti znanja

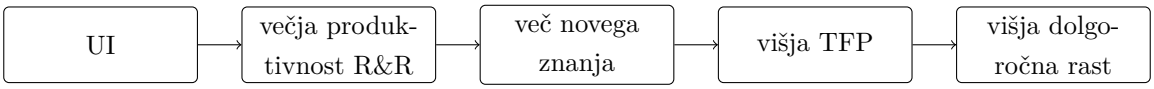
$$\gamma_t = s\, h_t^{\varphi+\beta-1}\, l^{1-\varphi}. \tag{8}$$

Če je $\varphi+\beta = 1$, je rast konstantna, če je $\varphi+\beta > 1$, rast narašča (Polanec 2014, str. 26–27). Če je $\varphi + \beta < 1$, rast z akumulacijo znanja upada (lastna izpeljava iz enačbe (8)).

V Romerjevem modelu iz leta 1990 podjetja vlagajo v R&R, ker jim patent prinese začasen monopolni dobiček, ki krije stroške inovacije. Preteklo znanje olajša nadaljnje raziskovanje (učinek "stati na ramenih velikanov"), večje število inovatorjev pa krepi konkurenco in zmanjšuje rente; dolgoročna rast je rezultat ravnotežja teh sil (Polanec 2014, str. 27–28; Romer 1990). Zapiski navajajo, da so bile družbene stopnje donosa na R&R višje od zasebnih in da naj bi R&R pojasnile do 66 % rasti TFP (Polanec 2014, str. 27–28). Poleg tega imajo splošnonamenske tehnologije neenakomerno rastno pot: najprej stroški učenja in komplementarnih investicij, šele nato hitrejša rast (Polanec 2014, str. 28; Bresnahan in Trajtenberg 1995).

3.5 Umetna inteligenca v modelih rasti: hipoteze

Nobeden od predstavljenih modelov UI neposredno ne obravnava, zato povezavo izpeljemo z interpretacijo. Aghion, Jones in Jones UI modelirajo kot najnovejšo obliko avtomatizacije (Aghion, B. F. Jones in C. I. Jones 2019). V naši nalogi UI nastopa kot dejavnik, ki lahko deluje na različne člene verige na sliki 3. Glede na to, kateri parameter modelov se spremeni, dobimo štiri hipoteze v preglednici 4.



Slika 3: Vzročna veriga, ki jo preizkušamo

Tabela 4: Hipoteze o vlogi UI in njihove napovedi

Hipoteza	Mehanizem v modelu	Napoved za podatke
H1: UI ne spremeni dolgoročne rasti	x ostane nespremenjen, oziroma $\varphi + \beta < 1$; več inputov dvigne raven, ne pa rasti	Rast TFP se med podobdobji sistematično ne spremeni, kljub rasti R&R in UI-patentov
H2: UI poveča stopnjo tehnološkega napredka x	Enkraten dvig x za Δx (enačbi (4) in (5))	Stopničast dvig rasti TFP za $(1-\alpha)\Delta x$, brez nadaljnjega pospeševanja
H3: UI poveča raziskovalne inpute ali njihovo produktivnost	γ je sorazmerna z $s\,l^{1-\varphi}$ (enačba (8))	Rast R&R in UI-patentov sledi (z zamikom) višja rast TFP, sorazmerna dvigu inputa
H4: UI poveča donose znanja ($\varphi + \beta > 1$)	γ narašča z akumulacijo znanja h	Rast TFP narašča skozi čas: 2010–2014 < 2015–2019 < 2020–2025

Vir: lastna zasnova na podlagi (Polanec 2014; Garín, Lester in Sims 2021).

Pri H2–H4 se učinek lahko pokaže z zamikom, ker splošnonamenske tehnologije zahtevajo komplementarne investicije (Polanec 2014, str. 28). Odsotnost učinka v kratkem obdobju zato hipotez ne ovrže, vztrajna odsotnost v daljšem obdobju pa jih oslabi. Patenti so le merljiv in delen izid raziskovanja, saj v Romerjevem modelu predstavljajo zaščito inovacije (Polanec 2014, str. 27–28). Ker TFP vsebuje tudi druge dejavnike (razdelek 3.1), preizkus pokaže le skladnost podatkov s posamezno hipotezo, ne vzročnosti.

4 Uporaba modela in povezava s podatki

Namen tega poglavja je povezati empirične ugotovitve z teorijo modela ter oceniti, v kolikšni meri so podatki skladni s hipotezami, oblikovanimi v prejšnjem poglavju.

4.1 R&R in ustvarjanje novega znanja

Empirične ugotovitve lahko najprej povežemo z osnovnim mehanizmom endogene teorije rasti. V Romerjevem okviru podjetja vlagajo v R&R, ker pričakujejo prihodnje donose iz novih proizvodov, postopkov in drugih oblik novega znanja. Močna rast širših ameriških izdatkov za R&R zato pomeni povečanje virov, ki so na voljo za raziskovalni proces.

Naslednji korak je pretvorba raziskovalnih inputov v novo znanje. Rast UI-patentne aktivnosti je skladna s tem, da se je povečala količina formaliziranih tehnoloških rezultatov, povezanih z umetno inteligenco. Patenti imajo v teoriji dvojno vlogo: inovatorju začasno omogočajo donos, hkrati pa z razkritjem znanja prispevajo k širjenju informacij in prihodnjim raziskavam. Zaradi takšnih prelivanj je lahko družbeni učinek raziskovanja večji od zasebnega učinka posameznega podjetja.

4.2 Umetna inteligenca in produktivnost raziskovalnega procesa

Za našo raziskovalno temo je ključno, da umetne inteligence ne obravnavamo le kot končni proizvod ali novo tehnologijo v proizvodnji, temveč tudi kot input v sam proces R&R. Če UI omogoči hitrejšo obdelavo podatkov in literature, avtomatizacijo rutinskih nalog, simuliranje rešitev ali učinkovitejše programiranje, lahko raziskovalci z enako količino dela in kapitala ustvarijo več novega znanja.

Na podlagi endogene teorije rasti bi večja učinkovitost uporabe UI v raziskovanju pomenila večjo produktivnost raziskovalnega sektorja. Empirični podatki kažejo povečanje raziskovalnih inputov, saj so se povečali tako skupni izdatki za R&R kot federalno financiranje UI R&R, hkrati pa se je povečala tudi z UI povrzana patentna aktivnost. Ti podatki so skladni z mehanizmom, po katerem večji raziskovalni inputi spremljajo več ustvarjenega znanja, ne omogočajo pa ločene ocene, če se je povečala tudi sama produktivnost raziskovalnega procesa. Iz agregatnih podatkov namreč ne moremo ugotoviti, kolikšen del povečanja inovacijske aktivnosti izhaja iz večjega obsega vloženih sredstev in kolikšen iz učinkovitejšega raziskovanja zaradi uporabe UI.

4.3 Prenos novega znanja v TFP

Tretji korak je prenos novega znanja v produktivnost proizvodnega sektorja. Če UI izboljša tehnologijo proizvodnje ali poveča učinkovitost raziskovanja, bi se njen dolgoročni učinek moral odraziti v TFP. Toda podatki ne kažejo preprostega sočasnega premika:

raziskovalni in inovacijski kazalniki so v analiziranem obdobju močno rasli, rast TFP pa je bila precej bolj neenakomerna.

Takšen rezultat je skladen z idejo splošnonamenske tehnologije iz profesorjevih zapiskov. Širše tehnološke spremembe pogosto zahtevajo komplementarne investicije, reorganizacijo in učenje, zato se lahko njihovi produktivnostni učinki pojavijo šele z zamikom (Polanec 2014). Pri UI to vključuje podatkovno infrastrukturo, računsko moč, programsko opremo, spremembe delovnih procesov in usposabljanje zaposlenih.

4.4 Primerjava napovedi modela z ugotovitvami

4.5 Primerjava napovedi modela z ugotovitvami

V teoretičnem delu smo oblikovali več možnih predpostavk o tem, kako lahko razvoj umetne inteligence vpliva na raziskovalni proces, tehnološki napredek in skupno faktorsko produktivnost. Njihove napovedi lahko zdaj neposredno primerjamo z opaženimi podatki za ZDA.

Tabela 5: Primerjava napovedi modela z empiričnimi ugotovitvami

Predpostavka	**Napoved modela**	**Empirična ugotovitev**	**Presoja**
UI ne spremeni dolgoročne stopnje rasti	Kljub povečanju R&R in UI-povezane inovacijske aktivnosti se dolgoročna rast TFP sistematično ne poveča. Več raziskovalnih inputov lahko poveča raven znanja in proizvodnje, ne pa nujno trajne stopnje rasti.	Povprečna rast TFP je znašala 0,80 % v obdobju 2010–2014, 0,64 % v obdobju 2015–2019 in 1,00 % v obdobju 2020–2025. Jasnega monotonega pospeševanja ni.	Podatki so s predpostavko skladni.
UI poveča stopnjo tehnološkega napredka	Povečanje stopnje tehnološkega napredka bi povzročilo višjo stopnjo rasti TFP po spremembi, brez nujnega nadaljnjega pospeševanja v naslednjih obdobjih.	V obdobju 2020–2025 je povprečna rast TFP višja kot v predhodnem obdobju, vendar je to obdobje močno zaznamovano s pandemskimi nihanji. Jasnega trajnega strukturnega preloma zato ne moremo identificirati.	Šibka skladnost.
UI poveča raziskovalne inpute ali produktivnost raziskovanja	Večji raziskovalni inputi oziroma učinkovitejše raziskovanje povečajo ustvarjanje novega znanja, temu pa lahko z zamikom sledi višja rast TFP.	Izdatki za R&R in UI-povezana patentna aktivnost so se močno povečali. Povprečna rast TFP je v zadnjem podobdobju višja, vendar časovnega zamika in velikosti učinka iz agregatnih podatkov ne moremo neposredno oceniti.	Delna skladnost.
UI poveča donose akumulacije znanja	Če več znanja dodatno povečuje produktivnost nadaljnjega raziskovanja, bi se morala rast TFP skozi čas pospeševati. To bi pomenilo, da velja 2010–2014 < 2015–2019 < 2020–2025.	Povprečne stopnje rasti TFP znašajo 0,80 %, 0,64 % in 1,00 %. Ker se je v drugem podobdobju rast TFP zmanjšala, napoved monotonega pospeševanja ni izpolnjena.	Podatki predpostavke ne podpirajo.

Primerjava pokaže, da podatki ne omogočajo nedvoumne potrditve ene same razlage. Najbolj so skladni z mehanizmom, po katerem večji raziskovalni inputi in večja inovacijska aktivnost povečujejo ustvarjanje novega znanja, medtem ko je prenos teh sprememb v trajno višjo agregatno TFP manj jasen. Povprečna rast TFP je v zadnjem podobdobju sicer višja, vendar podatki ne kažejo enakomernega pospeševanja skozi celotno obdobje, zato predpostavka o naraščajočih donosih akumulacije znanja ni podprta. Rezultati tako kažejo predvsem delno skladnost z mehanizmom endogene rasti, ne pa dokaz vzročnega učinka umetne inteligence na produktivnost.

5 Kritična presoja in zaključek

5.1 Odgovor na raziskovalno vprašanje

Raziskovalno vprašanje je bilo, ali rast vlaganj v umetno inteligenco in širjenje inovacij, povezanih z UI, v ZDA v obdobju 2010–2025 spremljata povečano ustvarjanje novega znanja in rast skupne faktorske produktivnosti ter kako lahko to povezavo pojasnimo z modelom endogene gospodarske rasti.

Analiza pokaže, da je prvi del povezave v podatkih precej jasen. Ameriški izdatki za R&R so se močno povečali, federalna vlaganja v UI R&R pa so po letu 2019 dosegla večmilijardne ravni. Hkrati je močno narasla tudi UI-povezana patentna aktivnost, kar je skladno z večjim ustvarjanjem formaliziranega tehnološkega znanja.

Pri TFP je odgovor bolj zadržan. V novejšem obdobju je mogoče opaziti nekoliko višjo povprečno rast, vendar je serija zelo volatilna in močno zaznamovana s pandemskimi šoki. Podatki zato ne kažejo jasnega in takojšnjega prenosa rasti UI in R&R v trajno višjo agregatno TFP. Ugotovitve so vseeno skladne z endogenim mehanizmom, po katerem večji raziskovalni inputi in učinkovitejše ustvarjanje znanja lahko dolgoročno povečajo produktivnost, pri čemer se učinek lahko pokaže z zamikom.

5.2 Presoja in omejitev analize

Endogena teorija rasti dobro pojasni predvsem povezavo med vlaganji v R&R, ustvarjanjem novega znanja in dolgoročnim tehnološkim napredkom. Za naš primer je posebej uporabna razlaga umetne inteligence kot inputa v raziskovalni proces, saj lahko UI poveča produktivnost raziskovanja in s tem potencialno pospeši nastajanje novega znanja. Koncept splošnonamenske tehnologije hkrati pojasni, zakaj se povečanje vlaganj in inovacijske aktivnosti ne odrazi nujno takoj v višji agregatni TFP, ampak se lahko učinek pokaže šele z zamikom.

- Največja omejitev analize je, da gre za opisno primerjavo časovnih vrst. Sočasna rast UI-kazalnikov, patentov in TFP ne pomeni, da je umetna inteligenca povzročila

rast produktivnosti. Vzročnost je lahko dvosmerna: višja produktivnost in dobički lahko podjetjem omogočijo več investicij v R&R, več vlaganj pa lahko pozneje spodbudi nadaljnjo produktivnost. Poleg tega na TFP vplivajo številni drugi dejavniki, zato brez kontrolne skupine, mikroekonomskih podatkov ali ustrezne identifikacijske strategije vzročnega učinka ne moremo oceniti.

- Druga omejitev je merjenje umetne inteligence. Federalni proračunski izdatki, patentni dokumenti in dejanska uporaba UI v podjetjih merijo različne faze inovacijskega procesa. Rast enega kazalnika zato ne pomeni nujno enake rasti vseh drugih. Posebej pazljivi moramo biti pri FY2025, kjer NITRD objavlja proračunsko zahtevo in ne realizirane porabe.

- Tretja omejitev je časovni zamik. Pri UI lahko to pomeni investicije v podatkovno infrastrukturo, računsko moč, programsko opremo, organizacijske spremembe in usposabljanje zaposlenih. Posledično lahko patentna in investicijska aktivnost naraščata več let pred tem, ko se učinek v večjem obsegu pokaže v agregatni TFP.

- Četrta omejitev je sama narava TFP. Ker gre za rezidual, se vanjo prenesejo napake pri merjenju kapitala, dela in kakovosti inputov. TFP poleg tehnologije zajema tudi organizacijo, alokacijo virov, ekonomije obsega in druge spremembe učinkovitosti. Zato ni pravilno vsakega povečanja TFP neposredno interpretirati kot tehnološki napredek, še manj pa kot učinek UI.

- Peta omejitev so patenti. Patentni dokumenti ne zajamejo vseh inovacij, saj podjetja del znanja varujejo drugače, nekatera znanja pa sploh niso patentabilna. Tudi med patentiranimi izumi so velike razlike v gospodarski vrednosti. Število patentov je zato predvsem količinski indikator in ne neposredna mera kakovosti oziroma ekonomskega pomena novega znanja.

Nazadnje je pomembna dolžina analiziranega obdobja. Največji razmah generativne UI se je zgodil šele v zadnjih letih, zato je leto 2025 verjetno prezgodnje za zanesljivo presojo dolgoročnega makroekonomskega učinka. Močni učinki se lahko najprej pokažejo v posameznih panogah in podjetjih, v agregatni TFP pa šele pozneje.

5.3 Zaključek

Rezultati kažejo, da je ameriško gospodarstvo v obdobju 2010–2025 povečalo tako širše vire za R&R kot dejavnosti, neposredno povezane z umetno inteligenco. Hkrati se je razširila merljiva UI-povezana inovacijska aktivnost. To je skladno z napovedjo endogene teorije rasti, da vlaganja v raziskovanje in ustvarjanje znanja predstavljajo pomemben vir tehnološkega napredka.

Najbolj previdni moramo biti pri sklepanju o agregatni produktivnosti. Trenutni podatki še ne omogočajo trditve, da je umetna inteligenca povzročila trajen skok TFP. Bolj utemeljen sklep je, da se je okrepil raziskovalni in inovacijski del mehanizma, medtem ko je morebitni dolgoročni produktivnostni učinek še težko ločiti od časovnih zamikov in drugih gospodarskih sprememb. Nadaljnje raziskave bi bilo zato smiselno usmeriti v sektorske in podjetniške podatke ter makroekonomsko primerjavo ponoviti čez nekaj let.

Literatura in viri

Aghion, Philippe, Benjamin F. Jones in Charles I. Jones (2019). »Artificial Intelligence and Economic Growth«. V: *The Economics of Artificial Intelligence: An Agenda*. Ur. Ajay Agrawal, Joshua Gans in Avi Goldfarb. Prvotno: NBER Working Paper 23928, 2017. University of Chicago Press.

Bresnahan, Timothy F. in Manuel Trajtenberg (1995). »General Purpose Technologies: Engines of Growth?« V: *Journal of Econometrics* 65.1, str. 83–108.

Garín, Julio, Robert Lester in Eric Sims (2021). *Intermediate Macroeconomics*. Različica 3.0.1, 12. maj 2021. Prosto dostopen učbenik. URL: https://ucilnica.fmf.uni-lj.si/pluginfile.php/177448/mod_resource/content/0/Garin%20%20Lester%20%20Sims%20%282024%29%20Intermediate%20Macro.pdf.

National Center for Science and Engineering Statistics (27. feb. 2026). *U.S. R&D Totaled $937 Billion in 2023; Estimate for 2024 Indicates Further Increase to $993 Billion*. InfoBrief NSF 26-314. U.S. National Science Foundation. URL: https://ncses.nsf.gov/pubs/nsf26314 (pridobljeno 25. 10. 2026).

Networking and Information Technology Research and Development Program (2024). *Artificial Intelligence R&D Investments Fiscal Year 2019–Fiscal Year 2025*. URL: https://www.nitrd.gov/ai-rd-investments/ (pridobljeno 20. 10. 2026).

OpenAI (30. nov. 2022). *Introducing ChatGPT*. https://chatgpt.com/. URL: https://openai.com/index/chatgpt/ (pridobljeno 25. 10. 2026).

Polanec, Sašo (2014). »Teorija rasti«. Zapiski predavanj pri makroekonomiji.

Romer, Paul M. (1986). »Increasing Returns and Long-Run Growth«. V: *Journal of Political Economy* 94.5, str. 1002–1037.

— (1990). »Endogenous Technological Change«. V: *Journal of Political Economy* 98.5, S71–S102.

U.S. Bureau of Labor Statistics (2026). *Total Factor Productivity – 2025*. URL: https://www.bls.gov/news.release/archives/prod3_03192026.htm (pridobljeno 20. 10. 2026).

United States Patent and Trademark Office (2025). *Artificial Intelligence Patent Dataset (AIPD) 2023 Update*. URL: https://www.uspto.gov/ip-policy/economic-research/research-datasets/artificial-intelligence-patent-dataset (pridobljeno 20. 10. 2026).